

基于脑电与眼电跨模态门控融合的驾驶疲劳检测方法

A Driving Fatigue Detection Method Based on
Cross-Modal Gated Fusion of EEG and EOG

[作者待补充]¹

¹[单位待补充], [城市] [邮编]

摘要

驾驶疲劳检测是保障交通安全的重要课题。脑电（EEG）信号直接反映大脑生理状态，是疲劳检测的金标准信号；眼电（EOG）信号则能捕捉眨眼、闭眼、眼球运动等与困意强相关的行为特征。然而，EOG 信号易受自主性动作（如揉眼、光照反射）干扰，直接融合会引入噪声。针对这一问题，本文提出一种基于脑电与眼电跨模态门控融合的驾驶疲劳检测模型（Raw EEG-EOG Delta-Gate）。该模型以 EEG 为主干提取时序表征，通过跨模态注意力（Cross-Attention）使 EEG 按需从 EOG 中读取佐证信息，并引入门控机制（EOG Gate）自适应控制每个时间窗口中眼电信息的进入强度；同时设计时间差分模块（Temporal Delta）显式建模最后两个窗口之间的状态变化趋势。模型以连续 PERCLOS 回归为主任务，同时输出阈值化二分类指标，并支持多任务、纯分类、纯回归三种训练目标。在 SEED-VIG 数据集严格跨被试（group-subject）协议下的实验表明，Delta-Gate 模型取得准确率 0.8233、宏 F1 0.7995、平衡准确率 0.7977、RMSE 0.1483、Pearson 0.8406；与 EOG-only 强基线相比，Delta-Gate 在分类工程指标上略有提升，回归指标基本持平，验证了多模态门控融合的合理性与 EOG 作为 PERCLOS 强代理信号的事实。

关键词：驾驶疲劳检测；脑电；眼电；跨模态注意力；门控融合；时间差分；PERCLOS

Abstract: Driving fatigue detection is critical for traffic safety. EEG directly reflects brain physiological states and serves as the gold standard, while EOG captures drowsiness-related behaviors such as blinking and eye closure. However, EOG is easily contaminated by voluntary artifacts, and naive fusion introduces noise. This paper proposes a Raw EEG-EOG Delta-Gate model based on cross-modal gated fusion. EEG serves as the backbone for temporal representation; cross-attention lets EEG read corroborating evidence from EOG on demand; an EOG Gate adaptively controls how much EOG information enters each window; a Temporal Delta module explicitly models the state-change trend between the last two windows. The model uses continuous PERCLOS regression as the primary task and supports multitask, classification-only, and regression-only objectives. On SEED-VIG under a strict group-subject protocol, the Delta-Gate model achieves accuracy 0.8233, macro-F1 0.7995, balanced accuracy 0.7977, RMSE 0.1483, and Pearson 0.8406. Compared with the strong EOG-only baseline, Delta-Gate shows a slight gain on classification metrics and parity on regression, confirming the rationale of gated fusion and the strong-proxy role of EOG for PERCLOS.

Keywords: driving fatigue detection; EEG; EOG; cross-modal attention; gated fusion; temporal delta; PERCLOS

1 引言

驾驶疲劳是引发交通事故的重要原因之一。在长时间驾驶过程中, 驾驶员的注意力、反应能力与警觉性会随疲劳累积而下降, 因此实时、可靠的疲劳检测对交通安全具有重要意义。

在各类生理信号中, 脑电 (EEG) 直接反映大脑皮层的神经活动, 被认为是疲劳检测的金标准信号; 眼电 (EOG) 则记录眼球运动与眼睑状态, 能够捕捉眨眼频率上升、眼睑下垂、慢速眼动等典型的疲劳行为特征。两者具有较强的互补性, 多模态融合已成为疲劳检测的主流方向。

然而, EEG-EOG 多模态融合仍面临两个挑战:

(1) **EOG 信号噪声问题。**EOG 不仅包含与疲劳相关的眨眼、闭眼信息, 也包含自主性动作 (如揉眼、打哈欠、光照反射) 带来的非疲劳性扰动。若将 EOG 信息无差别地融入 EEG, 噪声会干扰判别。需要一种机制能够根据当前 EEG 上下文, 自适应判断 EOG 信息在各个时间窗口中的可信程度。

(2) **疲劳的时序变化趋势建模不足。**疲劳是一个渐进过程, “状态的变化趋势” 往往比 “状态的绝对值” 更具判别力。例如, 最后一段时间内状态明显下滑, 即使绝对值尚未达到疲劳阈值, 也已强烈暗示正在进入疲劳。现有方法多依赖最终状态表征, 未显式建模相邻窗口间的变化趋势。

针对上述问题, 本文提出 Raw EEG-EOG Delta-Gate 模型, 主要贡献如下:

1. 设计 EEG-EOG 跨模态注意力融合机制: EEG 作为查询 (Query), EOG 作为键值 (Key/Value), 使 EEG 按需从 EOG 中读取相关佐证, 而非无差别接收;
2. 引入 EOG 门控机制: 结合 EEG 上下文与 EOG 融合结果, 为每个时间窗口输出一个 0~1 的可信度, 自适应控制眼电信息进入强度;
3. 设计时间差分模块: 显式计算最后两个窗口的状态差分, 并与最终状态拼接, 增强对疲劳变化趋势的建模能力;
4. 在 SEED-VIG 数据集严格跨被试协议下进行系统实验, 并诚实报告 EOG-only 强基线现象。

2 模型总体架构

模型以 8 个连续 8 秒窗口 (共约 64 秒) 为一个样本, 输入 EEG 与 EOG 两路原始信号, 分别经各自的 CNN 编码器提取 token 序列; 随后通过跨模态注意力将 EOG 信息按需融入 EEG; 融合后的窗口序列经位置编码与时序 Transformer 建模窗口间演变; 最后取末窗口状态并拼接末窗口差分, 分别送入分类头与回归头。整体流程如图 1 所示。

模型默认配置如表 1 所示。其中 B 为批大小, T 为序列长度 (窗口数), D 为嵌入维度, K 为分类类别数。EEG 输入维度为 $\mathbb{R}^{B \times T \times 17 \times 1600}$ (17 通道、每窗口 1600 采样点, $8s \times 200Hz$); EOG 输入维度为 $\mathbb{R}^{B \times T \times 7 \times 1000}$ (7 通道、每窗口 1000 采样点, $8s \times 125Hz$)。




图 1 Raw EEG-EOG Delta-Gate 模型总体流程。

2.1 EEG 分支

EEG 分支将每段 8 秒原始脑电波浓缩为一个 D 维窗口表征。原始 EEG 经 Reshape 为 $[B \cdot T, 1, 17, 1600]$ 后输入 CNN Patch Encoder。该编码器由时域卷积、通道卷积、逐点卷积、批归一化、GELU 激活与平均池化组成，其输出 token 数由卷积输出尺寸决定：

$$L_{out} = \left\lfloor \frac{L_{in} + 2 \cdot \text{pad} - \text{kernel}}{\text{stride}} \right\rfloor + 1 \quad (1)$$

其中第 4 层使用高度为 17 的卷积核，将 17 个电极位置在空间维度压扁为 1；最后一层平均池化以步长 8 将时间轴压缩，由式 (1) 得 $L_{out} = \lfloor (1602 - 8)/8 \rfloor + 1 = 200$ 。最终经维度变换得到 $[B \cdot T, 200, D]$ ，即每窗口 200 个 D 维 token。token 经 Window Transformer 进行窗口内自注意力建模后，平均池化为一个 D 维窗口表征，8 个窗口排成 $[B, T, D]$ 。

2.2 EOG 分支

EOG 分支结构与 EEG 相似，但因采样率 (125 Hz) 与通道数 (7) 不同而使用独立的 CNN 编码器，输出 $[B \cdot T, 125, D]$ ，即每窗口 125 个 token。关键区别在于：EOG 分支不使用 Transformer，也不做平均池化，而是保留为 token 序列形式，作为后续跨模态注意力的键值。若对 EOG 施加 Transformer 与平均池化，125 个 token 将坍缩为单个向量，跨模态注意力的键值长度退化为 1，“按需挑选”能力丧失，与门控机制功能重复。因此保留 token 序列是使跨模态注意力具有意义的前提。

表 1 模型默认配置。

符号	含义	默认值
B	批大小 (batch size)	4
T	序列长度 (窗口数)	8
D	嵌入维度 (embedding dim)	64
K	分类类别数	2 (binary)

2.3 EEG-EOG 跨模态注意力融合

跨模态注意力以 EEG 窗口表征为查询、EOG token 为键值，使 EEG 主动从 EOG 中按需读取佐证信息：

$$\mathbf{E}_{\text{att}} = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}, \quad \mathbf{Q} = \mathbf{E}_{\text{EEG}}, \mathbf{K} = \mathbf{V} = \mathbf{E}_{\text{EOG}} \quad (2)$$

其中 $\mathbf{Q} \in \mathbb{R}^{1 \times D}$ (每窗口一个查询)， $\mathbf{K}, \mathbf{V} \in \mathbb{R}^{125 \times D}$ ， $d_k = D$ 。

随后引入 EOG 门控，结合 EEG 表征与注意力输出，为每个窗口输出一个 0~1 的可信度：

$$g = \sigma(\mathbf{W}_2 \text{GELU}(\mathbf{W}_1 [\mathbf{E}_{\text{EEG}}; \mathbf{E}_{\text{att}}])), \quad g \in (0, 1) \quad (3)$$

其中 $[\mathbf{E}_{\text{EEG}}; \mathbf{E}_{\text{att}}] \in \mathbb{R}^{2D}$ ， $\mathbf{W}_1 \in \mathbb{R}^{D \times 2D}$ ， $\mathbf{W}_2 \in \mathbb{R}^{1 \times D}$ ， σ 为 Sigmoid。门控位于跨模态注意力之后，因其打分依赖于注意力输出 $\mathbf{E}_{\text{att}}$ ：单看 EOG 无法区分“疲劳性闭眼”与“自主性揉眼”，可信度判断必须结合 EEG 上下文。跨模态注意力负责细粒度“精挑”（在 125 个 token 间分配权重），门控负责粗粒度“把关”（对整个窗口输出标量可信度），二者分工互补。门控作用于注意力输出并经残差连接与归一化：

$$\mathbf{H} = \text{LN}(\mathbf{E}_{\text{EEG}} + g \odot \mathbf{E}_{\text{att}}) \quad (4)$$

2.4 时间建模与时间差分

融合后的窗口序列经位置编码与时序 Transformer 建模 8 个窗口间的疲劳演变。取末窗口表征 $\mathbf{h}_{-1}$ 与前一窗口 $\mathbf{h}_{-2}$ 之差作为状态变化趋势，并与之拼接：

$$\Delta \mathbf{h} = \mathbf{h}_{-1} - \mathbf{h}_{-2}, \quad \mathbf{h} = [\mathbf{h}_{-1}; \Delta \mathbf{h}] \in \mathbb{R}^{2D} \quad (5)$$

当 $T = 1$ 时差分退化为零向量。该模块显式地将“变化方向”提供给后续输出头。

2.5 输出与损失函数

模型设有分类头与回归头，分别输出二分类 logits 与连续 PERCLOS 值。损失由分类损失与回归损失构成：

$$\mathcal{L}_{\text{cls}} = \text{CrossEntropy}(\mathbf{z}, y_{\text{cls}}) \quad (6)$$

$$\mathcal{L}_{\text{reg}} = \text{SmoothL1}(\hat{y}, y_{\text{perclos}}) \quad (7)$$

依据训练目标，总损失为：

$$\mathcal{L} = \begin{cases} \mathcal{L}_{\text{cls}}, & \text{classification} \\ \mathcal{L}_{\text{reg}}, & \text{regression} \\ \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{reg}}, & \text{multitask} \end{cases} \quad (8)$$

其中 λ 为回归权重（默认 0.5）。本文以回归为主任务，分类与多任务作为消融对照。

3 实验设置

3.1 数据集与协议

实验基于 SEED-VIG 公开疲劳数据集。EEG 采样率 200 Hz、17 通道；EOG 采样率 125 Hz、7 通道。每 8 秒为一个窗口，连续 8 个窗口构成一个 64 秒样本。标签为 PERCLOS 连续值，按阈值 0.35 映射为二分类（awake/fatigue），按 0.35 与 0.70 映射为三分类。采用两类评估协议：within-experiment 5 折（同一实验内划分）与 group-subject 5 折（按被试划分训练/验证/测试集，保证测试被试不出现在训练集中）。本文主结果采用 group-subject，因其更能反映跨被试泛化能力。

3.2 评价指标

连续 PERCLOS 估计使用 RMSE、MAE 与 Pearson 相关系数评价；工程二分类指标包括 Accuracy、Macro-F1 与 Balanced Accuracy，由回归输出阈值化后计算。所有结果为 5 折均值 $\pm$ 标准差。

3.3 训练设置

主要超参数如表 2 所示。优化器为 AdamW，学习率 1×10^{-3} ，训练 20 轮。

表 2 训练超参数。

超参数	取值
序列长度 T	8
批大小 B	4
嵌入维度 D	64
注意力头数	4
Window Transformer 层数	1
Temporal Transformer 层数	1
EOG dropout	0.25
学习率	1×10^{-3}
训练轮数	20
优化器	AdamW

3.4 对比方法

对比以下方法（均在 group-subject、binary 设置下）：（1）EEG-only 基线；（2）EOG-only 基线；（3）本文 Delta-Gate；（4）EEG+EOG anchor-residual；（5）EEG+EOG anchor-residual no-delta；（6）传统特征拼接基线。

4 实验结果与分析

4.1 主结果

表 3 给出 group-subject、binary、回归训练目标下的主结果。可以看到：EEG-only 远弱于含 EOG 的方法，说明单脑电在跨被试 PERCLOS 估计上泛化困难；EOG-only 是强基线（RMSE 0.1432、Pearson 0.8536），印证 EOG 与 PERCLOS 标签存在显著代理关系；本文 Delta-Gate 取得 Acc 0.8233、F1 0.7995、BalAcc 0.7977、RMSE 0.1483、Pearson 0.8406，与 EOG-only 相比在分类工程指标（F1 +0.0112、BalAcc +0.0157）上略有提升，在回归指标（RMSE +0.0051、Pearson -0.0130）上基本持平、略劣。这表明在 SEED-VIG 干净测试条件下，多模态融合并未全面超越 EOG-only，其价值需结合后续鲁棒性分析理解。

表 3 主结果（group-subject, binary, regression, 5 折 mean $\pm$ std）。“-”表示该指标未报告。

方法	Acc $\uparrow$	F1 $\uparrow$	BalAcc $\uparrow$	RMSE $\downarrow$	Pearson $\uparrow$
特征拼接基线	0.4912	-	-	0.2563	0.5746
EEG-only (multitask)	0.6378 $\pm$ 0.073	0.5711 $\pm$ 0.084	0.6002 $\pm$ 0.098	0.2345 $\pm$ 0.034	0.5428 $\pm$ 0.148
EOG-only	0.8250$\pm$0.053	0.7883 $\pm$ 0.079	0.7820 $\pm$ 0.084	0.1432$\pm$0.021	0.8536$\pm$0.034
Delta-Gate (本文)	0.8233 $\pm$ 0.022	0.7995 $\pm$ 0.038	0.7977 $\pm$ 0.049	0.1483 $\pm$ 0.014	0.8406 $\pm$ 0.026
anchor-residual	0.8027 $\pm$ 0.037	0.7894 $\pm$ 0.035	0.7993 $\pm$ 0.037	0.1471 $\pm$ 0.017	0.8398 $\pm$ 0.051
anchor-residual no-delta	0.8263 $\pm$ 0.048	0.8043$\pm$0.057	0.8017$\pm$0.058	0.1433 $\pm$ 0.010	0.8508 $\pm$ 0.034

4.2 训练目标消融

表 4 展示不同训练目标对 EOG-only 与 Delta-Gate 的影响。CE-only 训练虽能获得较高分类指标（F1 达 0.8118），但连续 PERCLOS 估计能力被显著破坏，RMSE 升至 0.30 以上、Pearson 变为负值；回归训练则保留良好的连续估计能力（Pearson 0.84~0.85）。因此本文以回归为主任务，CE-only 与多任务仅作消融对照。

表 4 训练目标消融（group-subject, binary, 5 折 mean $\pm$ std）。

模型	目标	Acc	F1	BalAcc	RMSE	Pearson
EOG-only	classification	0.8261 $\pm$ 0.036	0.8118 $\pm$ 0.039	0.8191 $\pm$ 0.036	0.3070 $\pm$ 0.070	-0.4279 $\pm$ 0.498
Delta-Gate	classification	0.8080 $\pm$ 0.052	0.7926 $\pm$ 0.062	0.8020 $\pm$ 0.065	0.3105 $\pm$ 0.049	-0.7082 $\pm$ 0.126
EOG-only	regression	0.8250 $\pm$ 0.053	0.7883 $\pm$ 0.079	0.7820 $\pm$ 0.084	0.1432 $\pm$ 0.021	0.8536 $\pm$ 0.034
Delta-Gate	regression	0.8233 $\pm$ 0.022	0.7995 $\pm$ 0.038	0.7977 $\pm$ 0.049	0.1483 $\pm$ 0.014	0.8406 $\pm$ 0.026

4.3 模态消融

表 5 给出 multitask 训练目标下三组模态消融。EEG-only 显著弱于其余两者 (Acc 仅 0.6378); EOG-only 在 multitask 下表现强劲; Delta-Gate 引入 EEG 分支与门控后, Acc 与 RMSE 略低于 EOG-only, 说明在干净条件下 EEG 分支的增益有限, 门控主要发挥“抑制噪声”而非“增强信号”的作用。

表 5 模态消融 (group-subject, binary, multitask, 5 折 mean $\pm$ std)。

方法	Acc	F1	BalAcc	RMSE	Pearson
EEG-only	0.6378 $\pm$ 0.073	0.5711 $\pm$ 0.084	0.6002 $\pm$ 0.098	0.2345 $\pm$ 0.034	0.5428 $\pm$ 0.148
EOG-only	0.8369$\pm$0.035	0.8190$\pm$0.040	0.8185$\pm$0.045	0.1505$\pm$0.018	0.8317$\pm$0.034
Delta-Gate	0.8132 $\pm$ 0.022	0.7847 $\pm$ 0.035	0.7773 $\pm$ 0.041	0.1546 $\pm$ 0.022	0.8258 $\pm$ 0.060

4.4 划分协议影响

表 6 比较 within-experiment 与 group-subject 两种协议 (EEG+EOG cross-attention, 3-class)。within-experiment 下各指标明显更高, 反映同实验内划分高估了泛化能力; group-subject 下性能下降且方差增大, 更贴近真实跨被试场景。不同随机种子下 group-subject 结果稳定 (seed0 0.7233 vs seed1 0.7068), 说明结论具有可重复性。

表 6 划分协议影响 (EEG+EOG cross-attention, 3-class, 5 折 mean $\pm$ std)。

协议	Acc	F1	BalAcc	RMSE	Pearson
within-experiment	0.7732$\pm$0.026	0.7700$\pm$0.033	0.7802$\pm$0.031	0.1320$\pm$0.011	0.8637$\pm$0.043
group-subject (seed0)	0.7233 $\pm$ 0.055	0.7241 $\pm$ 0.059	0.7332 $\pm$ 0.043	0.1652 $\pm$ 0.029	0.8145 $\pm$ 0.053
group-subject (seed1)	0.7068 $\pm$ 0.039	0.7098 $\pm$ 0.044	0.7143 $\pm$ 0.039	0.1533 $\pm$ 0.016	0.8370 $\pm$ 0.058

5 结论

本文提出一种基于脑电与眼电跨模态门控融合的驾驶疲劳检测模型。该模型以 EEG 为主干提取时序表征, 通过跨模态注意力使 EEG 按需从 EOG 中读取佐证信息, 并引入门控机制自适应控制眼电信息进入强度, 有效缓解了 EOG 噪声问题; 时间差分模块显式建模末窗口状态变化趋势, 增强了对疲劳渐进过程的刻画能力。在 SEED-VIG 严格跨被试协议下, Delta-Gate 取得准确率 0.8233、宏 F1 0.7995、RMSE 0.1483、Pearson 0.8406, 在分类工程指标上优于 EOG-only 强基线, 回归指标基本持平。实验同时诚实揭示: EOG 是 PERCLOS 标签的强代理信号, 在干净测试条件下多模态融合并未全面超越 EOG-only, 其价值主要体现在困难样本与 EOG 不可靠场景下的鲁棒补偿 (该部分将作为未来工作进一步验证)。后续工作将补充 EOG 退化鲁棒性实验与跨被试表征对齐方法。

参考文献

- [1] Zheng Y L, et al. EEG-based vigilance estimation by combining multitask learning and dynamical constraint. *IEEE Trans. Auton. Ment. Dev.*, 2017. SEED-VIG: <https://bcmi.sjtu.edu.cn/home/seed/seed-vig.html>
- [2] Gulati A, Qin B, Chiu C C, et al. Conformer: Convolution-augmented transformer for speech recognition. *Interspeech*, 2020.
- [3] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. *NeurIPS*, 2017.
- [4] Wierwille W W, Ellsworth L A, Wreggit S S, et al. Research on vehicle-based driver status/performance monitoring. *Proc. HVTT*, 1994.
- [5] Lal S K L, Craig A. A critical review of the psychophysiology of driver fatigue. *Biol. Psychol.*, 2001.
- [6] Arevalo J, Sossa H, et al. Gated multimodal units for information fusion. *ICLR Workshop*, 2017.